PLE · EL PROYECTO · FICHA DE LA TAREA 5

Sistemas de diálogo: entender qué piden, y hacerlo

Para quien ha elegido un proyecto de **conversar**. Lo mínimo para empezar ya, junto al cuaderno de arranque `tarea-5-dialogo`. La sesión de conversar, más adelante, lo explica todo para toda la clase; esto no la sustituye.

---

1. La tarea, y para qué se usa hoy

Un **sistema de diálogo** conversa con una persona por turnos: un **turno** es lo que dice cada uno antes de que hable el otro. Hay dos clases, y se miden de manera distinta:

- **Orientados a tareas** (*task-oriented*): la conversación sirve para **hacer algo** (reservar, consultar, configurar, ejecutar una orden). Es lo que hacen los asistentes de reservas, de bancos y de atención al cliente, y los de voz del móvil. Acierta si la tarea queda hecha, y bien.
- **De conversación abierta** (*open-domain*, los *chatbots*): hablar por hablar, acompañar, responder a cómo se siente alguien. No hay tarea que completar: se juzga si la respuesta es adecuada.

```
usuario:   Quiero reservar la pista 2 el jueves a las 18
asistente: {"accion": "reservar", "pista": 2, "dia": "jueves", "hora": 18}
← lo que hace el programa
```

2. Cómo se ha hecho: la clásica y la moderna

La clásica, en conversación abierta: ELIZA (Joseph Weizenbaum, MIT, 1966). Reglas que buscan una palabra clave y devuelven una frase hecha con lo que dijo el usuario dado la vuelta («Me siento triste» → «¿Por qué te sientes triste?»). No entiende nada, y aun así a muchos les pareció que sí.

La clásica, orientada a tareas: marcos y huecos. Desde GUS (Bobrow y otros, 1977), un **marco** (*frame*) es la lista de datos que la tarea necesita, cada uno un **hueco** (*slot*) por rellenar. El sistema se parte en piezas:

Pieza	Qué hace	En las reservas de pádel
comprensión del lenguaje (*NLU*)	**detección de la intención** (clasificar la frase) y **rellenar huecos**: etiquetar los fragmentos que pueden rellenar alguno y extraer su valor	intención reservar; «el jueves» → día 2026-11-19, «a las seis» → hora 18:00, «la 2» → pista 2
estado del diálogo	lo que se sabe hasta ahora: la intención y los huecos rellenos, **de quién es el turno**, y las **obligaciones pendientes** (una pregunta hecha que espera respuesta)	reservar; jueves, ?, 2; turno del sistema; pendiente: nada

gestor del diálogo, o política (*dialogue manager*, *policy*)	qué hace el sistema ahora	pedir la hora, o reservar si está todo
generación de la respuesta	escribe la respuesta, normalmente con una plantilla	«¿A qué hora quieres la pista el jueves?»

Las reglas de las primeras piezas son expresiones regulares y palabras clave; hoy, en la industria, clasificadores entrenados (Rasa es la herramienta libre más usada). Lo bueno: hace sólo lo que está previsto, y se sabe por qué. Lo malo: lo que no está previsto, no lo entiende.

La moderna: un LLM con instrucciones. Un mensaje de **sistema** dice qué es el asistente y en qué formato responde (**salida estructurada**: un JSON con la acción y sus huecos), o qué funciones puede pedir que se ejecuten (**llamada a funciones**, *function calling*: el LLM escribe qué función y con qué datos; el programa la ejecuta). Entiende mucho más que las reglas, pero **puede hacer lo que no le han pedido**. Una salida real del LLM pequeño del cuaderno (Qwen2.5-0.5B, ejecutado el 13 de octubre):

```
usuario:   Resérvame una pista para el lunes
correcto:  {"accion": "preguntar", "falta": "hora"}
el LLM:    {"accion": "reservar", "pista": 1, "dia": "lunes", "hora": "09:00"}
                                        ← reserva a una hora que nadie ha dicho
```

3. Cómo se mide

Qué	Cómo
Cada turno	¿la acción es la correcta?, ¿cada hueco tiene su valor? El % de turnos con todo bien (lo que mide el cuaderno).
Cada conversación	la **tasa de tareas completadas** (¿acaba con la reserva correcta?) y **cuántos turnos** hicieron falta.
Conversación abierta	una **rúbrica** puntuada por personas, a ciegas (¿responde a lo que se dijo?, ¿es adecuada?, ¿suena natural?), por dos personas, y su **acuerdo**.

Cuidado con el *dev* y el *test*: unas reglas escritas mirando vuestros casos aciertan casi todos (el cuaderno da un 100 % que no significa nada). Hay que medir con peticiones **escritas por otras personas**, que no hayan visto las reglas: ése es el número que cuenta.

4. Los términos

turno

lo que dice cada participante antes de que hable el otro.

intención (*intent*)

el propósito del usuario en esa frase: reservar, consultar, anular…

marco (*frame*); hueco (*slot*); valor

los datos que necesita una tarea; cada uno de ellos (día, hora, pista); lo que lo rellena, en el formato del sistema. De ahí, **sistemas basados en marcos**.

estado del diálogo; seguimiento del estado (*dialogue state tracking*)

lo que el sistema sabe hasta ese turno (huecos, turno, obligaciones pendientes); y mantenerlo al día.

gestor del diálogo; política

la regla que decide qué hace el sistema en cada turno.

agente basado en LLM

un LLM que, en bucle, conversa y pide llamadas a funciones de un programa.

remuestreo (*bootstrap*)

para saber si la diferencia entre dos sistemas probados con los mismos casos es real: la sesión de sistemas de diálogo lo explica paso a paso.

salida estructurada; llamada a funciones

pedir al LLM la respuesta en un formato que un programa pueda leer (JSON); o que diga qué función ejecutar y con qué datos.

tasa de tareas completadas

el % de conversaciones que acaban con la tarea hecha y bien.

dev y *test*

los casos con que se construye y se ajusta (desarrollo), y los que se guardan para medir al final (prueba), como en la sesión de sintaxis.

5. Con vuestro proyecto, esta semana

1. Ejecutad el cuaderno `tarea-5-dialogo` tal cual, y mirad qué hace el LLM cuando falta un dato.
2. Cambiad sus diez peticiones por cinco o diez de **vuestro servicio** (un servidor de juego, comandos de una herramienta…), cada una con su acción correcta, y las reglas por las vuestras. Si vuestro proyecto es de conversación abierta, usad §5b (ELIZA) y la rúbrica de §6.
3. Pedid a **otra persona** que escriba diez peticiones sin ver vuestras reglas: serán el principio de vuestro *test*.
4. Escribid qué cuenta como acierto (la acción y qué huecos), y buscad a vuestro segundo anotador.

6. Para leer (si queréis más)

- Daniel Jurafsky y James H. Martin. *Speech and Language Processing*, 3.ª edición (en línea, gratis): el capítulo de *chatbots* y sistemas de diálogo. Todo lo de esta ficha, más despacio.
- Joseph Weizenbaum (1966). «ELIZA — A Computer Program for the Study of Natural Language Communication between Man and Machine». *Communications of the ACM* 9(1).
- Paweł Budzianowski y otros (2018). «MultiWOZ — A Large-Scale Multi-Domain Wizard-of-Oz Dataset for Task-Oriented Dialogue Modelling». *EMNLP 2018*. Diez mil conversaciones de

reservas, anotadas con huecos: cómo se anota y se mide.

- Hannah Rashkin y otros (2019). «Towards Empathetic Open-domain Conversation Models: a New Benchmark and Dataset». *ACL 2019*. Conversaciones sobre emociones, y cómo se juzga una respuesta empática.
